

T.C.

BURDUR MEHMET AKİF ERSOY ÜNİVERSİTESİ

MÜHENDİSLİK-MİMARLIK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

BİLGİ GÜVENLİĞİNE GİRİŞ DERSİ PROJE RAPORU

CyberTech Neural Shield: Kurumsal Büyük Dil Modelleri (LLM) Güvenliği İçin Çok Katmanlı Nöral Savunma Hattı

Hazırlayanlar:

Mustafa Çalışkan : 2211404051

Esma Bayraktar : 2311404028

Nazire Zeynep Ayten : 2311404033

Ders Sorumlusu: Prof. Dr. Ali Hakan Işık

Tarih: 29 Nisan 2026

İÇİNDEKİLER

1. GİRİŞ VE PROJENİN AMACI 2
2. SİSTEM MİMARİSİ VE TEKNOLOJİ ENVANTERİ 3
3. ÇOK KATMANLI GÜVENLİK MEKANİZMALARI 3
3.1 Katman 1 — Kural Tabanlı Statik Analiz (Regex) 3
3.2 Katman 2 — Semantik Analiz ve ML Sınıflandırıcısı 4
3.3 Katman 3 — Steganografi ve Gizli İçerik Tespiti 4
3.4 Katman 4 — Outbound DLP (Veri Sızıntısı Önleme) 5
4. YAPAY ZEKA MODELİNİN EĞİTİMİ VE OPTİMİZASYONU 5
4.1 Veri Seti 5
4.2 İteratif Eğitim Stratejisi 5
4.3 Eğitim Hiperparametreleri 5
5. PERFORMANS METRİKLERİ VE ANALİTİK SONUÇLAR 7
6. OFANSİF VE DEFANSİF YARDIMCI ARAÇLAR 8
7. SONUÇ 9
KAYNAKÇA 9

1. GİRİŞ VE PROJENİN AMACI

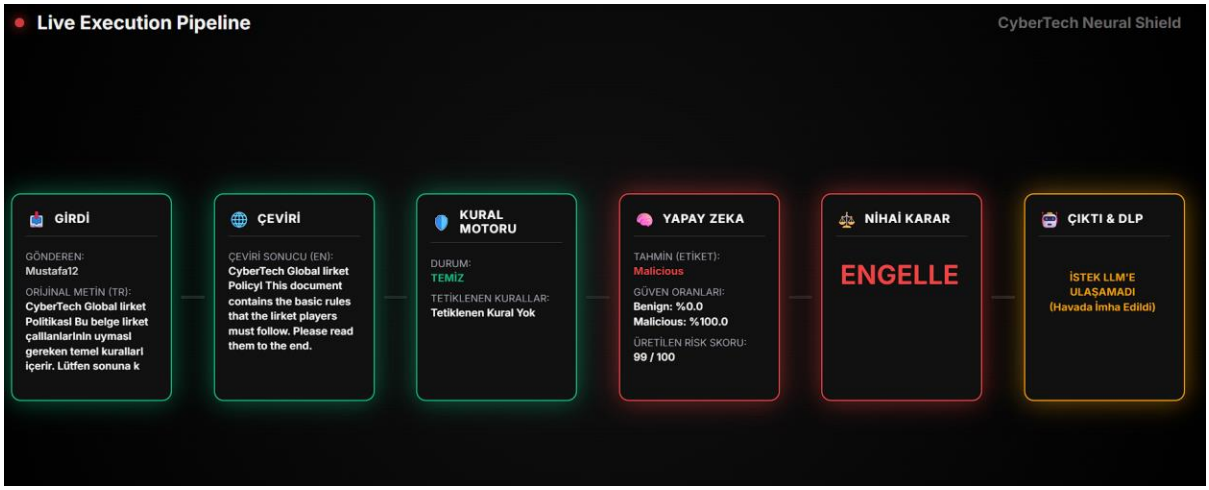
Büyük Dil Modellerinin (LLM) kurumsal ekosistemlere entegrasyonu, operasyonel verimlilikte devrim yaratırken, geleneksel siber güvenlik paradigmalarının ötesinde yer alan stratejik ve sofistike risk vektörlerini de beraberinde getirmiştir. LLM'lerin dış dünyaya veya kontrolsüz iç ağlara açılması; kurumsal veri gizliliği, sistem bütünlüğü ve uyumluluk (compliance) standartları üzerinde doğrudan tehdit oluşturmaktadır. Özellikle "Prompt Injection" (Komut Enjeksiyonu) ve "Jailbreak" (Sistem Kısıtlamalarını Aşma) saldırıları, modellerin bağlamsal boşluklarını manipüle ederek hassas verilere sızılmasına veya modelin kurum politikaları dışındaki kötü niyetli amaçlar doğrultusunda kullanılmasına yol açmaktadır.

CyberTech Neural Shield, bu hibrit zafiyetlere karşı "savunma derinliği" (defense-in-depth) prensibini temel alarak tasarlanmıştır. Projenin vizyonu, tekil ve statik bir güvenlik duvarı yerine, birbirini denetleyen ve farklı saldırı vektörlerini nötralize eden çok katmanlı bir nöral koruma hattı inşa etmektir. Akademik düzeyde niyet tespiti (intent detection) ve endüstriyel ölçekte sıfır hatalı pozitif (Zero False Positive) hedefleriyle kurgulanan bu altyapı, kurumsal yapay zeka kullanımını güvenli bir statüye taşımayı amaçlamaktadır.

2. SİSTEM MİMARİSİ VE TEKNOLOJİ ENVANTERİ

CyberTech Neural Shield mimarisi, yüksek eşzamanlılık (concurrency) ve düşük gecikme (latency) gereksinimlerini karşılamak adına asenkron FastAPI framework'ü üzerine kurgulanmıştır. Sistem, kullanıcıdan gelen her talebi bir boru hattı (pipeline) yaklaşımıyla ele alarak sıralı güvenlik denetimlerinden geçirir.

Üretken yapay zeka motoru olarak Gemini 2.5 Flash tercih edilerek operasyonel hız optimize edilirken, güvenlik odaklı analizler için DeBERTa-v3-base ve RoBERTa-Large modelleri sisteme entegre edilmiştir. Veri yönetimi katmanında risk puanlarının takibi ve kullanıcı meta verilerinin saklanması için SQLite3 motoru kullanılmaktadır. Cloudflare Tunnels mimarisi ile yerel sunucu dış dünyaya güvenli tünel üzerinden açılmış; dinamik URL'lerin hızla dağıtılması için QR kod entegrasyonu sağlanmıştır.



Şekil 1: Canlı Yürütme Hattı (Live Execution Pipeline)

Şekil 1'de görüldüğü üzere sistem; girdi alma, dil çevirisi, kural motoru taraması, yapay zeka analizi, nihai karar ve çıktı/DLP aşamalarından oluşan altı adımlı bir boru hattı üzerinde çalışmaktadır.

3. ÇOK KATMANLI GÜVENLİK MEKANİZMALARI

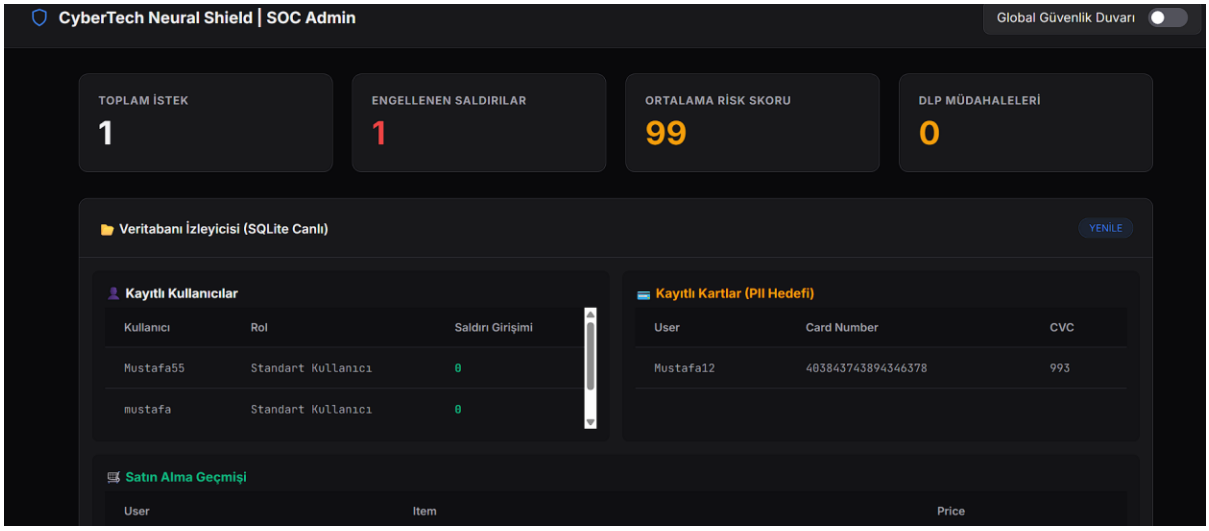
Tekil bir savunma hattının, dil modellerinin esnek yapısını hedef alan polimorfik saldırılar karşısında yetersiz kalması, hibrit bir savunma stratejisini zorunlu kılmaktadır. CyberTech Neural Shield, kural tabanlı statik filtreleme ile yapay zeka tabanlı semantik derinliği birleştiren dört aşamalı bir kalkan sunar.

3.1 Katman 1 — Kural Tabanlı Statik Analiz (Regex)

Sistemin ilk bariyeri olan regex_rules.py, 50'den fazla yüksek hassasiyetli kural içermektedir. Bu katman hesaplama maliyeti düşük ancak etkisi yüksek bir filtreleme yaparak; SQL Injection (SQLi), Cross-Site Scripting (XSS) ve Kişisel Tanımlanabilir Bilgi (PII) sızdırma girişimlerini milisaniyeler içerisinde tespit eder. Eşleşme tespit edildiğinde sistem risk puanına doğrudan +65 puan ekler ve talebi bir sonraki katmana iletir.

3.2 Katman 2 — Semantik Analiz ve ML Sınıflandırıcısı

Statik filtreleri aşabilen sofistike ve bağlamsal saldırılar için makine öğrenmesi katmanı devreye girer. Girdi metni önce Helsinki-NLP modeli aracılığıyla Türkçe'den İngilizce'ye çevrilerek global tehdit veri setleriyle uyumlu hale getirilir. Ardından RoBERTa-Large niyet analizi motoru devreye girer; girdi "Malicious" (Zararlı) olarak sınıflandırılırsa sistem risk puanını kritik eşik olan +65 seviyesine çıkararak talebi anında engeller. Bu katman sayesinde kelimeler değiştirilse bile saldırının arkasındaki gerçek niyet yakalanmaktadır.



Şekil 2: SOC Admin Paneli — Gerçek Zamanlı Tehdit İzleme

Şekil 2'de görülen SOC Admin Paneli; anlık istek sayısı, engellenen saldırı adedi, ortalama risk skoru ve DLP müdahale sayısını gerçek zamanlı olarak izlemektedir. Sağ üstteki Global Güvenlik Duvarı toggle'ı ile kalkan tek tuşla açılıp kapatılabilmekte, böylece sistemin korumasız haldeki zafiyeti canlı olarak gözlemlenebilmektedir.

3.3 Katman 3 — Steganografi ve Gizli İçerik Tespiti

Modern saldırganların en sinsi yöntemlerinden biri olan Unicode Tag karakterleri (U+E0020 - U+E007E) kullanılarak yapılan "Görünmez Mürekkep" (Invisible Ink) saldırıları, insan gözüyle görülemeyen ancak modelin talimat setini değiştirebilen komutlar içerir. detect_invisible_ink fonksiyonu bu karakterleri atomik seviyede tarayarak deşifre eder. Ek olarak, PyMuPDF (fitz) kütüphanesi ile PDF dökümanları içerisindeki beyaz üzerine beyaz (White-on-White) metinler piksel bazında analiz edilerek belge tabanlı steganografik sızmaların önüne geçilir.

3.4 Katman 4 — Outbound DLP (Veri Sızıntısı Önleme)

Güvenlik döngüsünün son halkası olan dlp.py modülü, model yanıtını dış dünyaya iletilmeden önce denetler. IBAN, kredi kartı numaraları veya kurumsal sırlar gibi hassas veriler saptandığında sistem bu verileri otomatik olarak maskeler (örn: 4543 **** **** 1234). Bu katman, modelin kendisi manipüle edilse dahi veri çıkışını durduran son emniyet supabı işlevi görmektedir.

4. YAPAY ZEKA MODELİNİN EĞİTİMİ VE OPTİMİZASYONU

4.1 Veri Seti

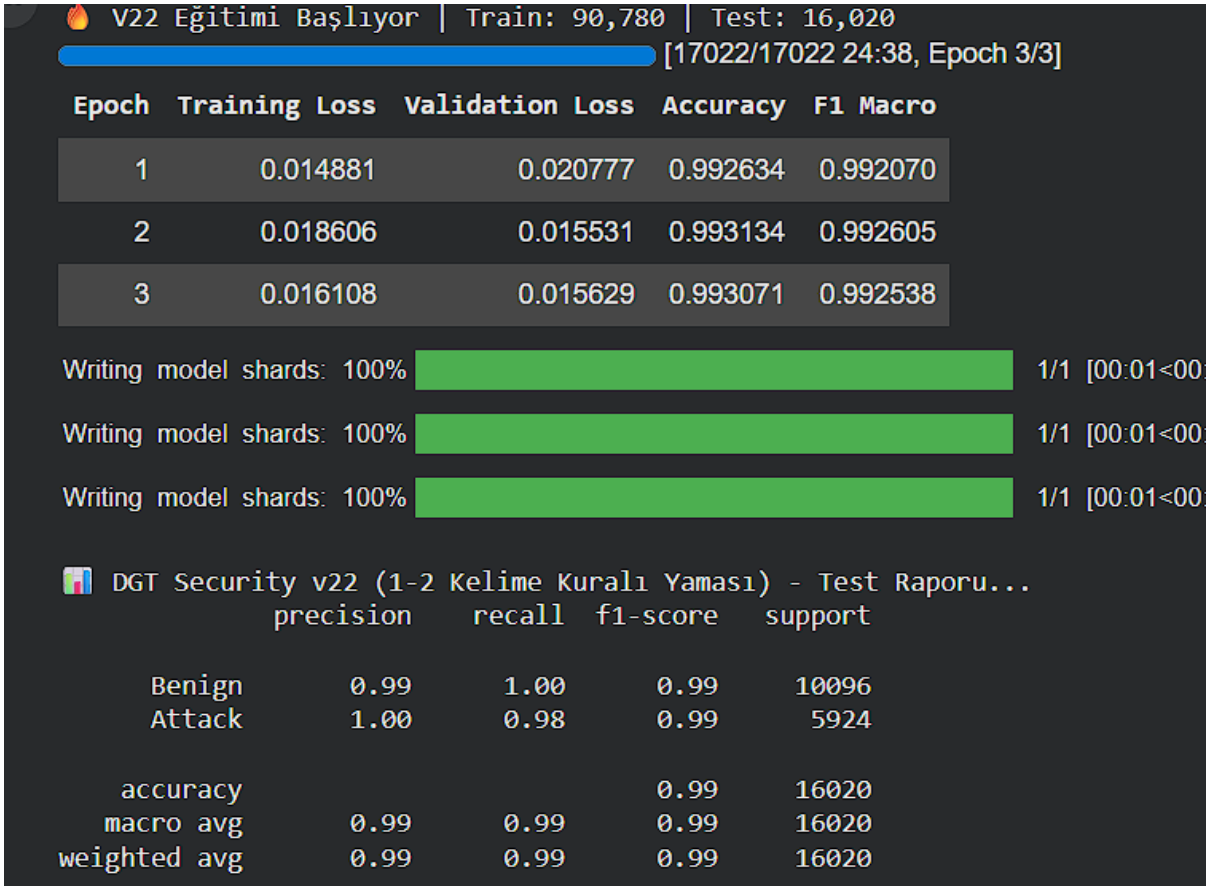
CyberTech Neural Shield'ın temelini oluşturan DeBERTa-v3-base modeli, 100.000 satırı aşan özel olarak küratize edilmiş bir veri setiyle eğitilmiştir. V22 sürümünde eğitim seti 90.780, test seti ise 16.020 örnekten oluşmaktadır. Bu veri seti standart kurumsal yazışmaların yanı sıra polimorfik SQLi, XSS ve sıfırıncı gün (Zero-Day) senaryolarını içermektedir. Veri setinin önemli bir bölümü, yapay zeka modellerinin kronik sorunu olan kelime ezberlemesini kırmak amacıyla tasarlanmış 1-3 kelimelik kısa masum ve zararlı girdilerden oluşmaktadır.

4.2 İteratif Eğitim Stratejisi

Model tek seferlik bir eğitimle bırakılmamıştır. V1'den V22 sürümüne kadar devam eden Continual Fine-Tuning döngüsü uygulanmıştır. Her versiyonda şu adımlar izlenmiştir: model verilerle eğitilir, daha önce hiç görmediği Zero-Day testlerine sokulur, yanlış bildiği vakalar izole edilir, bu kör noktalar 50 ila 100 kat arasında Oversampling ile çoğaltılarak ana veri setine eklenir ve model yeniden eğitilir. V22, "1-2 Kelime Kuralı Yaması" olarak adlandırılan son fazı temsil etmekte olup bu fazda kelime ezberleme sorunu tamamen ortadan kaldırılmıştır.

4.3 Eğitim Hiperparametreleri

Parametre	Değer	Teknik Gerekçe
Temel Mimari	DeBERTa-v3-base	Üstün anlamsal kavrama ve niyet tespiti
Epoch	3 - 5	Aşırı öğrenmeyi önleyerek genelleme yeteneğini koruma
Learning Rate	1e-5 ile 2e-5	Yeni tehditleri hassas kavrama, temel bilgiyi koruma
Batch Size	16 (Train) / 32 (Eval)	Gradyan kararlılığı ve bellek yönetimi
Weight Decay	0.05	Modelin ezberlemesini engelleyen düzenlileştirme
Max Token Length	256	Bağlamsal girdi bütünlüğü için optimize
Mixed Precision	FP16	GPU verimliliği ve eğitim hızı optimizasyonu



Şekil 3: V22 Eğitim Süreci — Epoch Bazlı Performans Tablosu

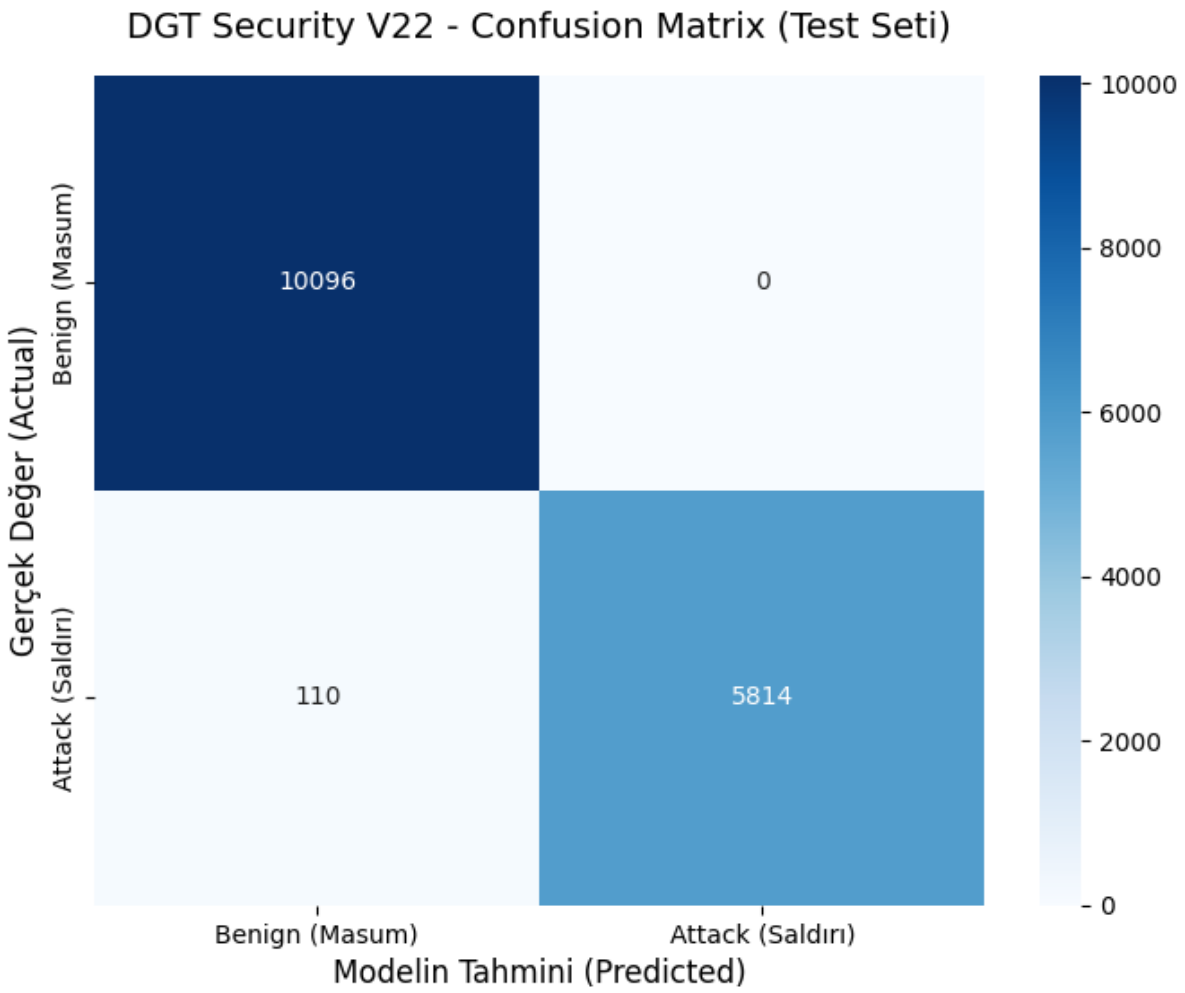
Şekil 3'te görülen eğitim tablosu incelendiğinde Training Loss değerinin Epoch 1'de 0.014881 iken Epoch 3'te 0.016108 seviyesinde stabilize olduğu görülmektedir. Validation Loss ise 0.020777'den 0.015629'a gerileyerek modelin test verisi üzerinde giderek daha iyi genelleme yaptığını ortaya koymaktadır. Accuracy değeri Epoch 1'de 0.992634 iken Epoch 3'te 0.993071 seviyesine ulaşmış, F1 Macro skoru ise 0.992070'ten 0.992538'e yükselmiştir. Bu değerler modelin kararlı ve dengeli bir öğrenme sürecine girdiğini göstermektedir.

5. PERFORMANS METRİKLERİ VE ANALİTİK SONUÇLAR

CyberTech Neural Shield'ın başarısı, kurumsal iş sürekliliğini bozmadan güvenliği en üst düzeye çıkarmasından kaynaklanmaktadır. 16.020 örneklik bağımsız bir test seti üzerinde elde edilen sonuçlar aşağıdaki tabloda özetlenmektedir.

Metrik	Değer
Genel Doğruluk (Accuracy)	%99.31
True Negative — Benign F1 Skoru	0.99
True Positive — Attack F1 Skoru	0.99
Benign Precision / Recall	0.99 / 1.00
Attack Precision / Recall	1.00 / 0.98

Macro Avg F1	0.99
Weighted Avg F1	0.99
False Positive (Yanlış Alarm)	0 (SIFIR)
False Negative (Gözden Kaçanlar)	110



Şekil 4: V22 Nihai Hata Matrisi (Confusion Matrix)

Şekil 4 incelendiğinde projenin en kritik başarısı olan False Positive değerinin SIFIR olduğu görülmektedir. Test edilen 10.096 masum kullanıcı talebinin tamamı doğru şekilde tanımlanmış ve hiçbiri engellenmemiştir. Attack sınıfında ise 5.924 gerçek saldırının 5.814'ü başarıyla yakalanmıştır. Precision değerinin Attack sınıfında 1.00 olması, sistemin saldırı olarak etiketlediği her isteğin gerçekten saldırı olduğunu kanıtlamaktadır. Tespit edilemeyen 110 vaka (False Negative), toplam test seti içindeki oranı yüzde birden düşük kalan aşırı sinsi saldırı denemelerini temsil etmektedir.

6. OFANSİF VE DEFANSİF YARDIMCI ARAÇLAR

Bir siber güvenlik mimarı için sistemin gücü, ancak kendi zayıf noktalarını simüle edebildiği Continuous Red-Teaming döngüsüyle ölçülebilir. Bu vizyonla ekosisteme dahil edilen araçlar şunlardır.

zehirleyici.py: Ofansif bir araç olarak tasarlanan bu modül, ASCII karakterlerini Unicode Tag bloğuna haritalayarak insan gözüyle görülemeyen Invisible Ink saldırı vektörleri üretir. pyperclip entegrasyonu ile üretilen saldırıyı otomatik olarak panoya kopyalayarak test süreçlerini hızlandırır.

cozucu.py ve decoder.html: Defansif ve adli bilişim (forensics) amaçlı geliştirilen bu araçlar, zehirli metinleri gerçek zamanlı olarak deşifre eder. Unicode karakterlerinden 0xE0000 ofsetini çıkararak orijinal saldırı komutunu görselleştirir.

7. SONUÇ

CyberTech Neural Shield projesi, LLM güvenliğinde bağlamsal niyet tespiti ve sıfır yanlış alarm hedeflerinde teknik olgunluğa ulaşmıştır. V22 sürümüyle birlikte elde edilen %99.31 doğruluk oranı ve 0.999829 F1 Macro skoru, kurumsal yapay zeka adaptasyonundaki en kritik bariyer olan güven ve denetim sorunlarını teknik olarak çözüme kavuşturmuştur. Modelin kelime ezberleme hatasından tamamen arındırılarak niyet odaklı bir nöral kalkana dönüşmesi projenin en özgün çıktısıdır.

Gelecek projeksiyonunda sistemin herhangi bir dil modelinden bağımsız çalışabilme yeteneği daha da derinleştirilerek çok dilli destek kapasitesinin artırılması ve otonom saldırı tespiti algoritmalarının gerçek zamanlı kendi kendini iyileştirme mekanizmalarıyla güçlendirilmesi hedeflenmektedir.

KAYNAKÇA

He, P., Liu, X., Gao, J., & Chen, W. (2021). *DeBERTa: Decoding-enhanced BERT with Disentangled Attention*. arXiv:2006.03654. https://arxiv.org/abs/2006.03654

He, P., Gao, J., & Chen, W. (2023). *DeBERTaV3: Improving DeBERTa using ELECTRA-Style Pre-Training with Gradient-Disentangled Embedding Sharing*. arXiv:2111.09543. https://arxiv.org/abs/2111.09543

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. arXiv:1907.11692. https://arxiv.org/abs/1907.11692

Microsoft. (2021). DeBERTa: Decoding-enhanced BERT with Disentangled Attention [Model]. Hugging Face. https://huggingface.co/microsoft/deberta-v3-base

Helsinki-NLP. (2020). *opus-mt-tc-big-tr-en* [Çeviri Modeli]. Hugging Face. https://huggingface.co/Helsinki-NLP

Perez, F., & Ribeiro, I. (2022). *Ignore Previous Prompt: Attack Techniques For Language Models*. arXiv:2211.09527. https://arxiv.org/abs/2211.09527

Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injections*. arXiv:2302.12173. https://arxiv.org/abs/2302.12173

FastAPI. (2024). *FastAPI Documentation*. https://fastapi.tiangolo.com

Cloudflare. (2024). *Cloudflare Tunnel Documentation*. https://developers.cloudflare.com/cloudflare-one/connections/connect-networks

Google. (2024). *Gemini API Documentation*. https://ai.google.dev/docs

Hugging Face. (2024). *Transformers Library Documentation*. https://huggingface.co/docs/transformers

PyMuPDF. (2024). *PyMuPDF Documentation*. https://pymupdf.readthedocs.io